

课程编号：

课程性质：专业必修

机器学习 实习报告

学院：_____ 测绘学院 _____

专业：_____ 测绘工程 _____

地点：武汉大学信息学部

班级：_____ 2106 _____

姓名：_____ 芦蓁 _____

学号：_____ 2021302141148 _____

教师：_____ 李杰 _____

2024 年 01 月 09 日

目录

1	Band1 和 Band31 可视化	1
1.1	训练集读入	1
1.2	获取两列数据并可视化	1
2	监督分类	2
2.1	多分类	2
2.2	二分类	4
3	非监督分类	5

1 Band1 和 Band31 可视化

1.1 训练集读入

在实习要求中提供了一个可参考的文件读入函数 `read_in()`，但要应用于本次实习还需做些修改。首先是 `pd.read_csv()` 函数的参数问题，因为要读取的五个数据文件的文件名中都含有汉字，故需要添加参数 “`engine='python'`” 才能够正常读取。`read_csv()` 返回的是一个表格，表格的每一列都要有名称，故还需添加参数 “`header=7`”，用以指定充当列名称的行，如果不添加这一参数则默认以第一行为列名称，查看数据文件就知道这显然是不对的。但数据文件第七行也不全是列名称，第一列的位置有一个分号，会影响数据的读入，本人选择把五个数据文件的第七行开头的分号都删去。经过以上修改，`read_in()` 函数完全可用于本次实习，只需要数据文件所在文件夹的路径这一唯一参数。

1.2 获取两列数据并可视化

按照任务书的要求，选取第 1 和第 31 波段的数据进行可视化，方式是绘制散点图，如图 1 所示。左上角为图例，不同类别用不同的颜色和符号加以区分。从中可看出，能用第 1 和第 31 两个特征区分的类别有 `tree`、`grass`、`path`。`road` 和 `roof` 交杂在一起，不好区分，但 `road` 和 `roof` 所合成的整体与其它三种地物较易分开。




图 1: 按 Band1 和 Band31 可视化

2 监督分类

2.1 多分类

2.1.1 对率回归

sklearn 库中用于训练学习器的函数 `fit()` 需要两个参数，分别是训练集的特征数据和训练集的标签数据，前者的格式必须是“float64”，后者的格式必须是“int32”，但直接读入的训练集的数据中，特征数据是“int64”，标签数据是字符串的形式，所以必须进行转化。本人定义了 `change()` 函数，用来将标签中的 `grass`, `path`, `road`, `roof`, `tree` 分别转化为 0~5，之后有用 `astype()` 函数将“int64”转为“float64”，将“int”转为“int32”。本次实习中用到的分类函数都是通过多次二分类实现多分类。对率回归最终共得到五个分类器，每个分类器的参数都是 191 个权重加一个偏置，每个测试样本经过五个分类器可得到分属于五个类别的概率预测值。测试集的混淆矩阵如表 1 所示。

表 1: 对率回归混淆矩阵

预测	真实					召回率
	grass	path	road	roof	tree	
grass	2673	1	44	0	12	0.9791
path	2	461	2	0	0	0.9914
road	0	0	1924	265	0	0.8789
roof	0	34	71	3545	0	0.9712
tree	18	0	0	0	689	0.9745
查准率	0.9926	0.9294	0.9427	0.9304	0.9829	

2.1.2 支持向量机

使用支持向量机进行多分类，总共构造了 10 个分类器，每个分类器都有 191 个权重和 1 个偏置，用以预测测试集中的每个样本分属于五类的概率。最终得到的混淆矩阵如表 2所示。

表 2: 支持向量机混淆矩阵

预测	真实					召回率
	grass	path	road	roof	tree	
grass	2705	0	0	0	25	0.9908
path	5	459	0	1	0	0.9871
road	0	0	1957	228	4	0.8940
roof	41	108	73	3428	0	0.9392
tree	13	0	6	0	688	0.9731
查准率	0.9787	0.8095	0.9612	0.9374	0.9596	

2.1.3 线性判别分析

使用线性判别分析进行多分类，总共构造了 5 个分类器，每个分类器都有 191 个权重和 1 个偏置，用以预测测试集中的每个样本分属于五类的概率。最终得到的混淆矩阵如表 3所示。

表 3: 线性判别分析混淆矩阵

预测	真实					召回率
	grass	path	road	roof	tree	
grass	2722	1	2	0	5	0.9971
path	4	457	2	1	1	0.9828
road	0	1	1733	451	4	0.7917
roof	0	124	1160	2363	3	0.6474
tree	14	0	4	9	680	0.9618
查准率	0.9934	0.7839	0.5974	0.8368	0.9812	

2.2 二分类

2.2.1 对率回归

本人实习过程中先做多分类，后做二分类，原因在于充当学习样例的鸢尾花分类是一个多分类问题，从多分类开始更容易上手。做二分类时只需对多分类的程序做如下一些修改：读入数据时标签只有“透水面”和“不透水面”；转换数据类型的函数也许做修改，本人又重新定义了 `change_2()` 函数，用来把“int64”转为“float64”，“int”转为“int32”；生成精度报告时的 `target_names` 参数改为只含 ‘0’ ‘1’ 的列表（之前含 1~5）。最终对率回归生成的学习器只有一个，含 191 个权重和 1 个偏置。一个学习器足以判断出某个测试集的样本属于正例或反例的概率，因为这二者和为 1。本人实习时，将不透水面命为反例，将透水面命为正例。最终的 ROC 曲线是以“为正例”的概率绘制的。对率回归的 ROC 曲线如图 2 所示， $auc = 0.9999$ 。




图 2: 对率回归的 ROC 曲线

2.2.2 支持向量机

支持向量机训练出了一个学习器，含 191 个权重和 1 个偏置。最终绘制出的 ROC 曲线如图 3 所示， $auc = 0.9999$ 。




图 3: 支持向量机的 ROC 曲线

2.2.3 线性判别分析

线性判别分析训练出了一个学习器，含 191 个权重和 1 个偏置。最终绘制出的 ROC 曲线如图 4所示， $auc = 0.9994$.




图 4: 线性判别分析的 ROC 曲线

3 非监督分类

本次实习中使用的非监督分类为主成分分析，将训练数据集从原本的 191 维降维到 90 维，使用 `PcA()` 函数即可实现，唯一的参数 `n_components` 指定了降维后的维数。依然使用 1.2 中使用过的代

码段选取第 1 和第 31 维进行可视化，只需要把数据集从 191 维的 data_train 换为 90 维的 data_train_90 即可。最终的可视化结果如图 5所示。




图 5: 降维后的第 1 和第 31 维

可以明显看出，降维后的第 1 和第 31 维是不容易将五类地物进行区分的，点的分布有很明显的交叠。但是 path 和 grass 两类地物是非常容易区分的，但是降维前也很容易凭借第 1 和第 31 维将这两类地物分开。